

# **BITÁCORA DE DECISIONES**

Proyecto de integración, validación y depuración de las bases de Saber 11 y Saber Pro

| N.º | MOMENTO DEL PROCESO                          | PROBLEMA O DECISIÓN QUE SURTIÓ                                                                                                                                                                           | OPCIONES EVALUADAS                                                                                                                                                                                    | DETERMINACIÓN ADOPTADA                                                                                                                                                                                                                                | RAZÓN DE LA ELECCIÓN                                                                                                                                                                                                                                            | EFFECTO EN LA CONSTRUCCIÓN DE LA BASE                                                                                                                                                                      |
|-----|----------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1   | 1. Delimitación del periodo de trabajo       | Fue necesario establecer qué periodos de las pruebas debían formar parte de la base de trabajo y cómo debía organizarse la información de Saber 11 y Saber Pro para permitir posteriormente su relación. | Trabajar únicamente con los periodos en los que ambas pruebas estuvieran disponibles; utilizar una ventana amplia de años; o reducir el periodo a los años con mayor disponibilidad y comparabilidad. | Se trabajó con la ventana temporal definida para el proyecto: información de Saber 11 disponible entre 2010 y 2025 y, posteriormente, información de Saber Pro entre 2014 y 2025, manteniendo el alcance establecido para la construcción de la base. | La decisión permitió disponer de una trayectoria temporal suficientemente amplia y conservar los periodos que podían aportar información para la posterior vinculación. No se redujo arbitrariamente la información disponible antes de revisar su utilidad.    | Definió el universo temporal de las bases y evitó mezclar periodos fuera del alcance establecido. También permitió identificar desde el comienzo que la cobertura de Saber 11 y Saber Pro no era idéntica. |
| 2   | 2. Reconocimiento de fuentes y documentación | Las bases provenían de diferentes archivos y periodos y no podía asumirse que los nombres, tipos o códigos de las variables fueran idénticos entre años.                                                 | Importar todas las bases y unir las directamente; revisar únicamente los nombres de las columnas; o contrastar las variables con los diccionarios oficiales antes de homologarlas.                    | Se decidió revisar las bases y sus diccionarios antes de realizar las uniones definitivas, identificando qué variables representaban el mismo concepto y cuáles presentaban cambios entre periodos.                                                   | La unión directa podía producir columnas separadas para una misma característica o, peor aún, relacionar variables con significados diferentes. El diccionario permitió tomar decisiones basadas en el significado de la variable y no únicamente en su nombre. | Se estableció una base metodológica para la homologación y se redujo el riesgo de errores conceptuales al combinar años.                                                                                   |
| 3   | 3. Determinación de variables necesarias     | Las fuentes contenían muchas variables y no todas eran necesarias para el objetivo de construir una base manejable y útil.                                                                               | Conservar todas las variables originales; seleccionar únicamente las variables necesarias; o seleccionar variables después de una primera unión.                                                      | Se seleccionaron las variables consideradas relevantes para la base final, manteniendo las variables necesarias para identificar, relacionar, caracterizar y analizar los registros.                                                                  | Mantener todas las variables habría aumentado innecesariamente el tamaño y complejidad de la base. La selección se hizo a partir del propósito del proyecto y de la revisión de los diccionarios.                                                               | Se obtuvo una base más manejable y se facilitó la homologación de nombres, tipos y categorías entre periodos.                                                                                              |
| 4   | 4. Incorporación de archivos a R             | Una parte importante de las bases estaba disponible en archivos de texto y debía ser incorporada a R sin modificar                                                                                       | Abrir y transformar los archivos manualmente; utilizar Excel como paso intermedio; o                                                                                                                  | Se decidió realizar la importación desde R mediante código, conservando los                                                                                                                                                                           | La lectura mediante código permite repetir el procedimiento y deja registrada la forma en que cada archivo fue                                                                                                                                                  | El proceso de incorporación quedó documentado y                                                                                                                                                            |

| N.º | MOMENTO DEL PROCESO                                          | PROBLEMA O DECISIÓN QUE SURTIÓ                                                                                                                                                                 | OPCIONES EVALUADAS                                                                                                                                                                                                       | DETERMINACIÓN ADOPTADA                                                                                                                                                                                                                    | RAZÓN DE LA ELECCIÓN                                                                                                                                                                                           | EFFECTO EN LA CONSTRUCCIÓN DE LA BASE                                                                                                                        |
|-----|--------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
|     |                                                              | manualmente los archivos originales.                                                                                                                                                           | realizar la lectura directamente desde R mediante código.                                                                                                                                                                | archivos originales sin modificaciones manuales.                                                                                                                                                                                          | incorporado. Además, evita que cambios manuales en Excel queden fuera de la trazabilidad.                                                                                                                      | reproducible dentro del flujo de trabajo.                                                                                                                    |
| 5   | 5. Estandarización de nombres y formatos                     | Las variables de distintos periodos podían aparecer con nombres o tipos diferentes, aunque conceptualmente representaran la misma característica.                                              | Conservar los nombres originales; renombrar manualmente sin verificar el significado; o establecer nombres finales comunes después de contrastar los diccionarios.                                                       | Se establecieron nombres y tipos homogéneos para las variables que debían permanecer en la base integrada, verificando previamente su correspondencia conceptual.                                                                         | La homologación solo se aplicó cuando existía evidencia de que las variables representaban el mismo concepto. No se asumió que dos nombres similares fueran necesariamente equivalentes.                       | Permitió apilar los periodos de manera coherente y evitó que una misma variable apareciera como varias columnas debido únicamente a cambios de nomenclatura. |
| 6   | 6. Revisión de categorías, códigos y faltantes               | Durante la revisión aparecieron variables con códigos numéricos, categorías textuales, valores especiales y registros faltantes. Esto podía afectar los conteos y los análisis posteriores.    | Eliminar todos los valores especiales; convertirlos automáticamente en NA; conservarlos sin revisar; o identificar su significado en el diccionario y aplicar el tratamiento correspondiente.                            | Se decidió revisar los códigos y categorías antes de convertir o eliminar valores, conservando la información cuando representaba una categoría válida y tratando como faltantes los códigos que correspondían a ausencia de información. | La decisión evitó confundir códigos válidos con datos faltantes. Se priorizó el significado documentado en las fuentes y se utilizaron conteos y frecuencias para comprobar los resultados.                    | Se redujeron errores de interpretación y se mantuvo la mayor cantidad posible de información válida.                                                         |
| 7   | 7. Corrección del formato de puntajes de Saber Pro 2014–2015 | En los resultados de Saber Pro de 2014 y 2015 se detectaron diferencias en la representación de los puntajes, particularmente relacionadas con valores decimales, frente a los demás periodos. | Eliminar los registros con decimales; redondearlos sin revisión; convertir toda la variable directamente a entero; o revisar primero el formato y conservar el valor numérico de acuerdo con la estructura de la prueba. | Se revisó el problema de formato antes de transformar los valores y se realizó la conversión de manera controlada para que los puntajes pudieran integrarse con los demás periodos sin alterar arbitrariamente su significado.            | La prioridad fue evitar que la diferencia de formato provocara pérdida de registros o errores de tipo. La transformación se hizo como parte de la estandarización, no mediante edición manual de los archivos. | Los periodos 2014 y 2015 pudieron incorporarse a la estructura común de Saber Pro, reduciendo incompatibilidades de tipo entre años.                         |
| 8   | 8. Consolidación de los periodos de Saber 11                 | Una vez revisados y homologados los archivos individuales, era necesario construir una sola base de Saber 11.                                                                                  | Unir los archivos mediante joins; concatenarlos por filas después de homologar las columnas; o trabajar cada año de manera independiente.                                                                                | Se decidió consolidar los periodos de Saber 11 mediante una unión vertical de los registros, después de                                                                                                                                   | Los archivos corresponden a periodos distintos de la misma prueba; por ello, la integración por filas permite conservar los estudiantes de cada periodo sin                                                    | Se obtuvo una base consolidada de Saber 11, manteniendo el periodo como                                                                                      |

| N.º | MOMENTO DEL PROCESO                                        | PROBLEMA O DECISIÓN QUE SURTIÓ                                                                                                                                | OPCIONES EVALUADAS                                                                                                                                                                                                                       | DETERMINACIÓN ADOPTADA                                                                                                                                                                                                           | RAZÓN DE LA ELECCIÓN                                                                                                                                                                                                       | EFFECTO EN LA CONSTRUCCIÓN DE LA BASE                                                                                                    |
|-----|------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
|     |                                                            |                                                                                                                                                               |                                                                                                                                                                                                                                          | estandarizar las variables que debían compartir estructura.                                                                                                                                                                      | crear relaciones artificiales entre registros.                                                                                                                                                                             | elemento necesario para identificar el origen temporal de cada registro.                                                                 |
| 9   | 9. Consolidación de los periodos de Saber Pro              | El mismo problema de consolidación se presentó con los diferentes periodos de Saber Pro, con diferencias de nombres, formatos y disponibilidad de variables.  | Unir directamente todos los archivos; excluir los periodos que presentaran diferencias; o homologar primero y posteriormente consolidar.                                                                                                 | Se homologaron las variables necesarias y luego se consolidaron los periodos de Saber Pro en una sola base.                                                                                                                      | La homologación previa era necesaria para evitar que R interpretara como variables distintas aquellas que representaban el mismo concepto en diferentes años.                                                              | Se construyó una base Saber Pro integrada y preparada para ser relacionada posteriormente con Saber 11.                                  |
| 10  | 10. Definición del mecanismo de vinculación entre pruebas  | Era necesario definir cómo relacionar los registros de ambas pruebas sin asumir que cada fila de una base correspondía automáticamente a una fila de la otra. | Relacionar por posición de fila; utilizar variables generales como género o programa; realizar una unión únicamente mediante identificadores compatibles; o construir una relación temporal que respetara la trayectoria del estudiante. | Se utilizó la información disponible para establecer la relación mediante los identificadores y criterios de vinculación definidos para el proyecto, evitando usar variables descriptivas como si fueran identificadores únicos. | Variables como género, año o programa pueden repetirse en miles de estudiantes y no permiten identificar individualmente a una persona. La relación debía apoyarse en información que permitiera distinguir los registros. | Se redujo el riesgo de emparejamientos incorrectos y se estableció una base para evaluar la tasa real de vinculación.                    |
| 11  | 11. Establecimiento de una diferencia temporal de dos años | Para relacionar la trayectoria de los estudiantes entre Saber 11 y Saber Pro era necesario decidir qué distancia temporal utilizar entre ambas pruebas.       | Relacionar el mismo año; utilizar un año de diferencia; utilizar dos años de diferencia; o permitir cualquier diferencia temporal.                                                                                                       | Se aplicó un rezago de dos años entre Saber 11 y Saber Pro para la construcción de la relación temporal.                                                                                                                         | El criterio buscó representar de manera razonable el tránsito entre la presentación de Saber 11 y la posterior presentación de Saber Pro, evitando asumir que ambas pruebas ocurren en el mismo año.                       | La relación temporal se volvió más consistente con la trayectoria académica esperada y permitió controlar el emparejamiento por periodo. |
| 12  | 12. Revisión de coincidencias múltiples y duplicados       | Durante la construcción de la relación podía existir más de un registro asociado a un mismo identificador o más de una coincidencia potencial.                | Aceptar todas las coincidencias; eliminar duplicados automáticamente; seleccionar una coincidencia sin criterio; o                                                                                                                       | Se revisó la existencia de duplicados y coincidencias múltiples antes de aceptar la relación como válida, evitando                                                                                                               | Una duplicación puede ser producto de la estructura real de los datos, de múltiples presentaciones o de un problema de integración.                                                                                        | Se mejoró el control de calidad de la unión y se evitó interpretar como error                                                            |

| N.º | MOMENTO DEL PROCESO                                              | PROBLEMA O DECISIÓN QUE SURTIÓ                                                                                                                                                                        | OPCIONES EVALUADAS                                                                                                                                                                                    | DETERMINACIÓN ADOPTADA                                                                                                                                                                             | RAZÓN DE LA ELECCIÓN                                                                                                                                                                                                              | EFEECTO EN LA CONSTRUCCIÓN DE LA BASE                                                                                                           |
|-----|------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
|     |                                                                  |                                                                                                                                                                                                       | revisar la multiplicidad antes de decidir.                                                                                                                                                            | eliminar registros sin conocer primero la causa.                                                                                                                                                   | Eliminarla automáticamente podía producir pérdida de información.                                                                                                                                                                 | cualquier repetición sin haberla diagnosticado.                                                                                                 |
| 13  | 13. Investigación de la diferencia aproximada de 2.000 registros | Después de la integración y los controles de conteo se observó una diferencia aproximada de 2.000 registros respecto a la cantidad esperada en una de las etapas.                                     | Eliminar la diferencia mediante ajustes manuales; asumir que era un error del código; revisar los identificadores y criterios de inclusión; o aceptar la diferencia sin comprobación.                 | Se decidió investigar la diferencia mediante conteos, revisión de identificadores y comprobación de los criterios de inclusión, sin inventar una causa mientras no existiera evidencia suficiente. | Una diferencia en el número de registros no demuestra por sí sola que la unión esté incorrecta. Debía determinarse si correspondía a registros sin coincidencia, duplicados, restricciones temporales u otra causa identificable. | La diferencia quedó tratada como un punto de validación y no como un dato que debía corregirse artificialmente.                                 |
| 14  | 14. Ajuste del tratamiento de valores faltantes                  | En una etapa de limpieza se intentó eliminar valores faltantes de forma general y el resultado produjo una pérdida extrema de observaciones, llegando a una base sin registros en una de las pruebas. | Eliminar todas las filas con cualquier NA; eliminar NA únicamente en las variables necesarias para cada análisis; conservar los faltantes; o imputarlos automáticamente.                              | Se corrigió el tratamiento generalizado de NA y se evitó utilizar una eliminación indiscriminada de filas como procedimiento de limpieza de toda la base.                                          | Una fila puede tener un valor faltante en una variable y, al mismo tiempo, contener información válida en muchas otras. Eliminar la fila completa por cualquier NA podía destruir gran parte de la información.                   | Se recuperaron observaciones válidas y el tratamiento de faltantes pasó a depender de la variable y del propósito específico de cada operación. |
| 15  | 15. Comprobación mediante dimensiones, conteos y frecuencias     | Era necesario comprobar que las transformaciones no hubieran producido pérdidas, duplicaciones o cambios inesperados en la distribución de las variables.                                             | Confiar únicamente en que el código se ejecutara sin errores; revisar visualmente una pequeña muestra; comparar dimensiones y nombres; o combinar dimensiones, conteos, frecuencias y valores únicos. | Se utilizaron controles de dimensiones, conteos, frecuencias, valores únicos y revisión de categorías antes de considerar terminada una transformación.                                            | Que R no produzca un mensaje de error no significa que el resultado sea correcto. Los conteos y frecuencias permiten detectar pérdidas o cambios que no generan errores sintácticos.                                              | Se fortaleció la validación de cada etapa y se generó evidencia para aceptar o corregir las transformaciones.                                   |
| 16  | 16. Control de la variable de género                             | La variable de género presentaba categorías F y M y era necesario verificar que la recodificación y la integración no hubieran alterado su distribución.                                              | Conservar los códigos originales; recodificar F y M; eliminar registros NA; o convertir categorías sin revisar su frecuencia.                                                                         | Se conservaron las categorías F y M como categorías diferenciadas y se revisó explícitamente la cantidad de registros y la presencia de NA.                                                        | La frecuencia observada permitió comprobar que las categorías esperadas estaban presentes y que los valores faltantes eran identificables en                                                                                      | La variable quedó disponible para validaciones y análisis posteriores, manteniendo                                                              |

| N.º | MOMENTO DEL PROCESO                                            | PROBLEMA O DECISIÓN QUE SURTIÓ                                                                                                                                                                    | OPCIONES EVALUADAS                                                                                                                                                       | DETERMINACIÓN ADOPTADA                                                                                                                                      | RAZÓN DE LA ELECCIÓN                                                                                                                                                        | EFFECTO EN LA CONSTRUCCIÓN DE LA BASE                                                                                                                                     |
|-----|----------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|     |                                                                |                                                                                                                                                                                                   |                                                                                                                                                                          |                                                                                                                                                             | lugar de desaparecer silenciosamente.                                                                                                                                       | identificados los registros faltantes.                                                                                                                                    |
| 17  | <b>17. Comprobación de los límites de las escalas</b>          | Las escalas de las dos pruebas no son iguales: Saber 11 utiliza puntajes de 0 a 500 y Saber Pro de 0 a 300. Esto podía generar errores al revisar valores extremos o al interpretar conversiones. | Tratar ambos puntajes como si tuvieran la misma escala; estandarizarlos automáticamente; o conservar sus escalas originales y validar sus rangos por separado.           | Se conservaron las escalas originales y se verificaron los rangos de cada prueba de manera independiente: Saber 11 entre 0 y 500 y Saber Pro entre 0 y 300. | Los puntajes pertenecen a sistemas de medición diferentes y no deben interpretarse como equivalentes únicamente por compartir el nombre de 'puntaje'.                       | Se evitó una interpretación incorrecta de los valores y se estableció un criterio de validación específico para cada prueba.                                              |
| 18  | <b>18. Separación entre construcción de la base y análisis</b> | Durante el proyecto surgieron resultados estadísticos y gráficos que podían analizarse, pero todavía era necesario asegurar la calidad de la base integrada.                                      | Realizar el análisis estadístico mientras se seguía modificando la base; cerrar primero la estructura y validación; o trabajar simultáneamente sin separar ambas etapas. | Se priorizó terminar y validar la construcción de la base antes de considerar cualquier análisis como resultado definitivo del proyecto.                    | Analizar una base que aún está cambiando puede hacer que los resultados no sean comparables entre versiones. Primero debía establecerse una versión consistente y validada. | Se separaron las etapas de construcción y análisis, facilitando la trazabilidad y reduciendo el riesgo de interpretar resultados derivados de una base todavía inestable. |