

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

Proyecto de integración, validación y depuración de las bases de Saber 11 y Saber Pro

MAPA GENERAL DE FASES

FASE	CONTENIDO
FASE 0	DEFINICIÓN DE LA METODOLOGÍA Y RUTA DE TRABAJO
FASE 1	CONSTRUCCIÓN E IMPORTACIÓN DE SABER 11
FASE 2	CONSOLIDACIÓN DE SABER 11
FASE 3	CONSTRUCCIÓN E IMPORTACIÓN DE SABER PRO
FASE 4	CONSOLIDACIÓN DE SABER PRO
FASE 5	CRUCE Y CRITERIO TEMPORAL
FASE 6	INTEGRACIÓN DE LAS TRES FUENTES
FASE 7	LIMPIEZA Y ESTANDARIZACIÓN

FASE 0. DEFINICIÓN DE LA METODOLOGÍA Y RUTA DE TRABAJO

INTERACCIÓN 1

Objetivo de la consulta: Establecer las condiciones de trabajo para desarrollar de principio a fin el proyecto de Estadística Industrial, definiendo una metodología organizada y rigurosa para el análisis de las bases de datos, su preparación, homologación, integración y posterior análisis estadístico en RStudio. Asimismo, establecer criterios de reproducibilidad, validación y documentación que permitan mantener la trazabilidad de las decisiones tomadas durante el proyecto.

PROMPT

Quiero que me ayudes a desarrollar de principio a fin un proyecto de Estadística Industrial en RStudio, siguiendo estrictamente la guía, rúbrica y documentos del profesor, especialmente las bases y diccionarios de Saber 11 y Saber Pro.

Trabajaremos de forma ordenada, rigurosa y paso a paso. Antes de escribir código, analiza los documentos e identifica los objetivos, bases y variables necesarias, procedimientos estadísticos, entregables, criterios de evaluación y orden de trabajo. No te adelantes ni inventes información.

Preparación de datos

Antes de unir las bases, revisaremos variables, tipos, formatos, faltantes, duplicados, inconsistencias, codificaciones e identificadores. Compararemos las variables entre años y construiremos un diccionario de homologación:

Variable final | Base/Año | Nombre original | Significado | Tipo | Observaciones

No debemos asumir que variables con nombres similares son equivalentes; debemos comprobar su significado y codificación.

Unión y validación

Antes de cada join, explica qué bases se unirán, qué identificador se utilizará, por qué, qué tipo de unión corresponde y qué riesgos existen. Después, verificaremos que no se pierdan registros, no se generen duplicados y la información quede correctamente relacionada.

Código y metodología

El código debe ser reproducible, automatizado, organizado y reutilizable, evitando procesos manuales innecesarios. Usa parámetros, funciones, nombres claros, comentarios y *checks* cuando corresponda. Explica brevemente qué hace cada procedimiento, por qué se realiza y qué resultado esperamos.

Organización y bitácora

Seguiremos las etapas que establezca la guía: preparación, limpieza, homologación, unión, validación, análisis, visualización y resultados.

Todo deberá poder documentarse en la bitácora mediante prompts, respuestas, código, resultados, gráficas, decisiones y verificaciones, manteniendo la trazabilidad:

qué hicimos → por qué → cómo → resultado → cómo lo verificamos.

Actúa como mi asesor técnico: señala errores o riesgos antes de continuar, recomienda la mejor alternativa cuando existan varias y solicita la información faltante en lugar de asumirla.

Prioridad: cumplir la rúbrica, mantener la calidad de los datos, utilizar código reproducible, validar cada procedimiento y documentar todo el proceso.

Primero analiza los documentos que te proporcione y explícame el plan de trabajo. No comiences a desarrollar código hasta realizar esta revisión.

Fecha: Agosto 14 2026

Etapas: Fase 0. Definición de la metodología y ruta de trabajo

Respuesta obtenida: Se estableció un plan de trabajo para desarrollar el proyecto de Estadística Industrial en RStudio de manera ordenada, rigurosa y reproducible. Como primera etapa, se realizará una revisión detallada de la guía, rúbrica, bases de datos y diccionarios de Saber 11 y Saber Pro para identificar los objetivos del proyecto, las variables requeridas, los procedimientos estadísticos, los criterios de evaluación y los entregables. Antes de realizar cualquier unión o transformación, se verificará la estructura, tipos de datos, identificadores, valores faltantes, duplicados, codificaciones e inconsistencias de cada base. Posteriormente, se construirá un diccionario de homologación que permita comprobar la correspondencia entre variables de diferentes años y bases. Una vez validada esta información, se procederá con la limpieza, homologación, unión y validación de las bases, comprobando que no se pierdan registros ni se generen duplicados. Finalmente, se desarrollará el análisis estadístico, las visualizaciones y la interpretación de resultados. Todo el proceso será documentado en la bitácora mediante la relación entre lo realizado, su justificación, el procedimiento utilizado, los resultados obtenidos y las respectivas verificaciones. No se desarrollará código hasta completar la revisión documental inicial.

Verificación aplicada:

Se comparó la respuesta con las instrucciones establecidas en la guía y rúbrica del proyecto, verificando que la metodología propuesta respetara el orden de trabajo solicitado y que no se realizaran uniones, transformaciones o análisis sin revisar previamente las bases y sus diccionarios.

Resultado:

La respuesta fue aceptada como plan inicial de trabajo. Se estableció que el siguiente paso será analizar detalladamente los documentos proporcionados por el profesor para identificar los requisitos exactos del proyecto antes de comenzar con la programación en RStudio.

FASE 1. CONSTRUCCIÓN E IMPORTACIÓN DE SABER 11

INTERACCIÓN 2

Objetivo de la consulta: Obtener un código sencillo y reutilizable en RStudio que permita importar cualquier base de datos de Saber 11 entre 2010-I y 2025-II, cambiando únicamente el año y periodo, manteniendo la estructura original de cada base.

PROMPT

Chat, como primer paso quiero cargar en RStudio las bases de Saber 11 que tengo desde 2010-I hasta 2025-II. Todas están guardadas en la misma carpeta y con el mismo formato de nombre, solo cambia el año y el periodo.

Necesito un código sencillo donde solo tenga que cambiar el periodo que quiero cargar, por ejemplo, 2010I o 2025II, sin modificar el resto del código.

Por ahora solo quiero importar las bases, sin limpiar, modificar ni unir nada. También quiero que el código me muestre cuántas filas y columnas tiene la base y sus nombres de variables para verificar que se cargó correctamente.

Ten en cuenta que las variables pueden cambiar entre periodos; eso lo revisaré después con los diccionarios oficiales.

Fecha: 14 agosto 2026

Etapas: Fase 1. Construcción e importación de saber 11

Respuesta obtenida:

```
saber11_2010I <- read_delim(
  "C:/Users/eduar/OneDrive/Escritorio/PRUEBA SABER 11/Examen_Saber_11_2010I.txt",
  delim = ";",
  show_col_types = FALSE,
  na = c("", "NA")
)
saber11_2010I <- saber11_2010I %>%
  select(
    periodo,
    estu_consecutivo,
    estu_estudiante,
    estu_depto_reside,
    cole_jornada,
    cole_bilingue,
    cole_area_ubicacion,
    cole_calendario,
    cole_naturaleza,
    fami_educacionmadre,
    fami_educacionpadre,
    fami_estratovivienda,
```

```
fami_tienecomputador,  
fami_tieneinternet,  
)
```

Verificación aplicada: Se ejecutó el código en RStudio con diferentes periodos y se verificó que los archivos fueran encontrados y cargados correctamente. Se revisaron las dimensiones de las bases y los nombres de las variables para comprobar que la importación se realizara sin modificar la información original.

Resultado:

El código permitió importar correctamente las bases de datos de los periodos seleccionados mediante un único parámetro. Se obtuvo una estructura reutilizable para cargar las demás bases, teniendo en cuenta que las variables pueden variar entre periodos y que su homologación se realizará posteriormente mediante los diccionarios oficiales.

FASE 2. CONSOLIDACIÓN DE SABER 11

INTERACCIÓN 3

Objetivo de la consulta: Unir en una sola base todas las bases de datos de Saber 11 de los diferentes periodos y eliminar los registros completamente duplicados, manteniendo únicamente la información necesaria para el proyecto.

PROMPT

Okey Chat, ya tengo cargadas en RStudio las bases de datos de Saber 11 de cada periodo, desde 2010-I hasta 2025-II, y ya seleccioné las variables que voy a utilizar. Ahora quiero unir todas estas bases en una sola base general.

Necesito un código sencillo y organizado que me permita unir las listas y que, después de la unión, identifique y elimine los registros que estén completamente duplicados. También quiero que el código me muestre cuántos registros había antes y después de eliminar duplicados y cuántos duplicados se eliminaron, para poder verificar que el proceso se hizo correctamente.

Por ahora solo quiero hacer la unión y eliminación de duplicados, sin realizar todavía otros procesos de limpieza, transformación u homologación.

Fecha: 14 agosto 2026

Etapas: Fase 2. Consolidación de saber 11

Respuesta obtenida:

```
saber11 <- bind_rows(
  saber11_20101,
  saber11_20102,
  saber11_20111,
  saber11_20112,
  saber11_20121,
  saber11_20122,
  saber11_20131,
  saber11_20132,
  saber11_20141,
  saber11_20142,
  saber11_20151,
  saber11_20152,
  saber11_20161,
  saber11_20162,
  saber11_20171,
  saber11_20172,
  saber11_20181,
  saber11_20182,
  saber11_20191,
  saber11_20192,
  saber11_20201,
  saber11_20202,
  saber11_20211,
  saber11_20212,
```

```
saber11_20221,  
saber11_20222,  
saber11_20231,  
saber11_20232,  
saber11_20241,  
saber11_20242,  
saber11_20251,  
saber11_20252  
)  
saber11 <- saber11 %>%  
  distinct(periodo, estu_consecutivo, .keep_all = TRUE)
```

Verificación aplicada:

Se comparó el número de registros antes y después de la unión y de la eliminación de duplicados. También se verificó la cantidad de duplicados eliminados y las dimensiones finales de la base para comprobar que el proceso se realizara correctamente.

Resultado:

Se obtuvo una base consolidada con los diferentes periodos de Saber 11. Los registros completamente duplicados fueron eliminados y se confirmó mediante los conteos que la información quedó integrada correctamente, sin realizar todavía otros procesos de limpieza o transformación.

FASE 3. CONSTRUCCIÓN E IMPORTACIÓN DE SABER PRO

INTERACCIÓN 4

Objetivo de la consulta: Obtener un código reutilizable en RStudio para importar las bases de Saber Pro de los diferentes periodos, permitiendo cambiar fácilmente el periodo y las variables necesarias

PROMPT

Okey Chat, ahora que ya terminamos de cargar y unir las bases de Saber 11, quiero hacer el mismo proceso con las bases de Saber Pro. Necesito un código parecido al anterior, donde solo tenga que cambiar el periodo y las variables que quiero utilizar para cargar cada base.

Quiero que el código sea sencillo, organizado y reutilizable, y que por ahora solo se encargue de importar correctamente cada base de Saber Pro, sin realizar todavía limpieza, homologación ni unión. También quiero una verificación para confirmar que la base se cargó correctamente.

Fecha: 14 agosto 2026

Etapas: Fase 2. Construcción e importación de saber pro

Respuesta obtenida:

```
## RUTA RAPIDA PARA LOS ARCHIVOS DE SABER PRO
```

```
{r}
```

```
ruta_pro <- "C:/Users/eduar/OneDrive/Escritorio/PRUEBA SABER PRO"
```

```
## BASE LIMPIA SABER PRO 2014
```

```
{r}
```

```
saberpro_2014 <- read.delim(
  file.path(ruta_pro, "Examen_Saber_Pro_Genericas_2014.txt"),
  sep = ";",
  header = TRUE,
  stringsAsFactors = FALSE,
  check.names = FALSE
) %>%
select(
  periodo,
  estu_consecutivo,
  estu_estudiante,
  estu_depto_reside,
  inst_cod_institucion,
  inst_nombre_institucion,
  estu_snies_prgmacademico,
  estu_prgm_academico,
  estu_nucleo_pregrado,
  estu_genero,
```

```
fami_educacionmadre,  
fami_educacionpadre,  
fami_estrato vivienda,  
fami_tiene computador,  
fami_tiene internet,  
mod_ingles_punt,  
mod_razona_cuantitat_punt,  
mod_lectura_critica_punt,  
mod_competen_ciudadana_punt,  
mod_comuni_escrita_punt,  
)
```

Verificación aplicada:

Se ejecutó el código con los periodos seleccionados y se verificó que las bases fueran cargadas correctamente, revisando sus dimensiones y las variables disponibles.

Resultado:

El código propuesto fue considerado adecuado porque permite importar las bases de Saber Pro de forma sencilla y reutilizable, cambiando únicamente el periodo y las variables necesarias. Además, incluye verificaciones para confirmar que la información se cargó correctamente.

FASE 4. CONSOLIDACIÓN DE SABER PRO

INTERACCIÓN 5

Objetivo de la consulta: Unir en una sola base las diferentes bases de datos de Saber Pro previamente cargadas en RStudio y eliminar los registros completamente duplicados, manteniendo la información seleccionada para el proyecto.

PROMPT

Okey Chat, ya tengo cargadas en RStudio las bases de datos de Saber Pro de los diferentes periodos y ya seleccioné las variables que voy a utilizar. Ahora quiero unir todas estas bases en una sola base general.

Necesito un código sencillo, organizado y reproducible que permita unir todas las bases de Saber Pro y, después de la unión, identificar y eliminar los registros que estén completamente duplicados.

Quiero que el código también realice las verificaciones necesarias: mostrar el número de registros antes y después de la unión, identificar cuántos registros duplicados existen, indicar cuántos se eliminan y mostrar las dimensiones finales de la base.

Por ahora, el objetivo es únicamente unir y eliminar duplicados, sin realizar todavía procesos adicionales de limpieza, transformación u homologación de variables. Si encuentras algún riesgo o inconsistencia que pueda afectar la unión, indícamelo antes de ejecutar el procedimiento y no asumas información que no haya sido verificada.

Fecha: 14 agosto 2026

Etapa: Fase 4 Consolidación de saber pro

Respuesta obtenida:

```
saberpro_total <- bind_rows(  
  saberpro_2014,  
  saberpro_2015,  
  saberpro_2016,  
  saberpro_2017,  
  saberpro_2018,  
  saberpro_2019,  
  saberpro_2020,  
  saberpro_2021,  
  saberpro_2022,  
  saberpro_2023,  
  saberpro_2024  
) %>%  
  distinct().
```

Verificación aplicada:

Se verificó que las bases fueran compatibles para la unión y se comparó el número de registros antes y después del proceso. También se identificaron los registros completamente duplicados, se contabilizaron los eliminados y se revisaron las dimensiones finales de la base consolidada.

Resultado:

La propuesta fue aceptada. El código permitió consolidar las bases de Saber Pro en una sola base y eliminar los registros completamente duplicados. Las verificaciones realizadas permitieron confirmar la cantidad de registros eliminados y comprobar que la base final quedó correctamente estructurada para continuar con las siguientes etapas del proyecto.

FASE 5. CRUCE Y CRITERIO TEMPORAL

INTERACCIÓN 6

Objetivo de la consulta: Filtrar la base “cruce de examen 11. Saber Pro” para obtener únicamente los estudiantes que presentaron Saber 11 entre 2010-I y 2024 y Saber Pro entre 2014 y 2024, estableciendo un rezago mínimo de dos años entre ambas pruebas. Además, se busca eliminar registros duplicados para obtener una base adecuada para el análisis posterior

PROMPT

Okey Chat, el siguiente paso es trabajar con la base cruce de examen 11. Saber Pro, que ya tengo disponible. Necesito un código en RStudio que filtre esta base para quedarnos únicamente con los estudiantes que hayan presentado Saber 11 entre 2010-I y 2024 y Saber Pro entre 2014 y 2024.

Además, quiero aplicar un rezago mínimo de dos años entre la presentación de Saber 11 y Saber Pro. Esto significa que debemos verificar correctamente los periodos de cada estudiante y conservar únicamente los casos donde exista una diferencia de al menos dos años, evitando estudiantes que presentaron ambas pruebas en el mismo periodo, con poca diferencia de tiempo o incluso Saber 11 después de Saber Pro.

También necesito que el código identifique y elimine los registros duplicados.

Quiero que el código sea organizado, reproducible y que incluya verificaciones antes y después del filtro: cantidad de estudiantes, periodos y duplicados eliminados. No asumas cómo están codificados los periodos; primero revisa los nombres y formatos de las variables correspondientes en la base y, si existe alguna inconsistencia, indícame antes de aplicar el filtro.

Fecha: 16 agosto 2024

Etapas: Fase 5. Cruce y criterio temporal

Respuesta obtenida:

```
cruce <- read.delim(
  "C:/Users/eduar/Downloads/Cruce Examen Saber 11 - Examen Saber Pro.txt",
  sep = ";",
  header = TRUE,
  stringsAsFactors = FALSE,
  check.names = FALSE
)

cruce_saber11_saberpro <- cruce %>%
  mutate(
    anio_sb11 = as.numeric(substr(periodo_sb11, 1, 4)),
    anio_sbpro = as.numeric(substr(periodo_sbpro, 1, 4))
  ) %>%
  filter(
```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
anio_sb11 >= 2010 & anio_sb11 <= 2024,  
  
anio_sbpro >= 2014 & anio_sbpro <= 2024,  
(anio_sbpro - anio_sb11) >= 2  
) %>%  
select(  
  estu_consecutivo_sb11,  
  periodo_sb11,  
  estu_consecutivo_sbpro,  
  periodo_sbpro  
) %>%  
distinct()
```

Verificación aplicada:

Se revisaron las variables correspondientes a los periodos de presentación de Saber 11 y Saber Pro y se verificó su formato antes de realizar el filtro. Posteriormente, se comparó la cantidad de registros antes y después del filtrado, se comprobó que los estudiantes cumplieran el rezago mínimo de dos años y se identificaron y contabilizaron los registros duplicados eliminados.

Resultado:

Propuesta aceptada. El procedimiento permitió obtener una base filtrada con los estudiantes que cumplen los rangos de años establecidos y el rezago mínimo de dos años entre las pruebas. También se eliminaron los registros duplicados y se realizaron las verificaciones correspondientes para confirmar que la base quedó preparada para continuar con el análisis.

FASE 6. INTEGRACIÓN DE SABER 11, SABER PRO Y TABLA DE CRUCE

INTERACCIÓN 7

Objetivo de la consulta: Preparar y unir las bases de Saber 11, Saber Pro y Cruce Saber 11–Saber Pro, diferenciando las variables de cada prueba mediante los sufijos `_sb11` y `_sbpro`, y utilizando los identificadores correspondientes para relacionar correctamente la información.

PROMPT

Okey Chat, ahora vamos a realizar una de las partes más importantes del proyecto: unir las tres bases de datos: Saber 11, Saber Pro y Cruce Saber 11–Saber Pro. Quiero que tengamos mucho cuidado para no perder información ni generar duplicados.

Primero necesito preparar las bases de Saber 11 y Saber Pro. Quiero cambiar el nombre de las variables que seleccionamos anteriormente agregándoles el sufijo `_sb11` para Saber 11 y `_sbpro` para Saber Pro. No debemos modificar las variables identificadoras que se necesiten para realizar el cruce, ya que estas deben conservarse para poder relacionar correctamente las bases.

Después, en el mismo bloque de código, quiero realizar la unión de las tres bases utilizando los identificadores que correspondan según la estructura real de las bases y el procedimiento que ya hemos establecido. No quiero que asumas los identificadores: primero verifica cuáles son las variables que permiten relacionarlas y explica qué tipo de unión corresponde.

Finalmente, agrega verificaciones antes y después de la unión para comprobar el número de registros, posibles duplicados, coincidencias y pérdida de información. Si existe algún riesgo de que la unión genere duplicados o elimine estudiantes, detente y señálame antes de ejecutar el cruce. No realices otras transformaciones que no sean necesarias para esta etapa.

Fecha: 16 agosto 2026

Etapas: Fase 6. Integración de saber 11, saber pro y tabla de cruce

Respuesta obtenida:

Preparar Saber 11

```
saber11_final <- saber11 %>%
  rename(
    periodo_sb11 = periodo,
    estu_consecutivo_sb11 = estu_consecutivo,
    estu_estudiante_sb11 = estu_estudiante,
    cole_bilingue_sb11 = cole_bilingue,
    cole_area_ubicacion_sb11 = cole_area_ubicacion,
    cole_calendario_sb11 = cole_calendario,
    cole_naturaleza_sb11 = cole_naturaleza,
    punt_c_naturales_sb11 = punt_c_naturales,
    punt_ingles_sb11 = punt_ingles,
    punt_matematicas_sb11 = punt_matematicas,
    punt_lectura_critica_sb11 = punt_lectura_critica,
    punt_sociales_ciudadanas_sb11 = punt_sociales_ciudadanas,
    fami_educacionmadre_sb11 = fami_educacionmadre,
    fami_educacionpadre_sb11 = fami_educacionpadre,
```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
fami_estratovivienda_sb11 = fami_estratovivienda,  
fami_tienecomputador_sb11 = fami_tienecomputador,  
fami_tieneinternet_sb11 = fami_tieneinternet,  
punt_global_sb11 = punt_global,  
estu_depto_reside_sb11 = estu_depto_reside,  
cole_jornada_sb11 = cole_jornada,  
percentil_c_naturales_sb11 = percentil_c_naturales,  
percentil_ingles_sb11 = percentil_ingles,  
percentil_lectura_critica_sb11 = percentil_lectura_critica,  
percentil_matematicas_sb11 = percentil_matematicas,  
percentil_sociales_ciudadanas_sb11 = percentil_sociales_ciudadanas,  
percentil_global_sb11 = percentil_global,  
)
```

Preparar Saber Pro

```
saberpro_final <- saberpro_total %>%  
  rename(  
    periodo_sbpro = periodo,  
    estu_consecutivo_sbpro = estu_consecutivo,  
    estu_estudiante_sbpro = estu_estudiante,  
    mod_competen_ciudadana_punt_sbpro = mod_competen_ciudadana_punt,  
    mod_comuni_escrita_punt_sbpro = mod_comuni_escrita_punt,  
    mod_ingles_punt_sbpro = mod_ingles_punt,  
    mod_lectura_critica_punt_sbpro = mod_lectura_critica_punt,  
    mod_razona_cuantitat_punt_sbpro = mod_razona_cuantitat_punt,  
    inst_cod_institucion_sbpro = inst_cod_institucion,  
    inst_nombre_institucion_sbpro = inst_nombre_institucion,  
    estu_snies_prgramacademico_sbpro = estu_snies_prgramacademico,  
    estu_prgm_academico_sbpro = estu_prgm_academico,  
    estu_fechanacimiento_sbpro = estu_fechanacimiento,  
    estu_genero_sbpro = estu_genero,  
    fami_educacionmadre_sbpro = fami_educacionmadre,  
    fami_educacionpadre_sbpro = fami_educacionpadre,  
    fami_estratovivienda_sbpro = fami_estratovivienda,  
    fami_tienecomputador_sbpro = fami_tienecomputador,  
    fami_tieneinternet_sbpro = fami_tieneinternet,  
    estu_nucleo_pregrado_sbpro = estu_nucleo_pregrado,  
    estu_depto_reside_sbpro = estu_depto_reside,  
    mod_ingles_pnal_sbpro = mod_ingles_pnal,  
    mod_razona_cuantitativo_pnal_sbpro = mod_razona_cuantitativo_pnal,  
    mod_lectura_critica_pnal_sbpro = mod_lectura_critica_pnal,  
    mod_competen_ciudadana_pnal_sbpro = mod_competen_ciudadana_pnal,  
    mod_comuni_escrita_pnal_sbpro = mod_comuni_escrita_pnal,  
    punt_global_sbpro = punt_global,  
    mod_ingles_pnal_sbpro = mod_ingles_pnal,  
    mod_razona_cuantitativo_pnal_sbpro = mod_razona_cuantitativo_pnal,  
    mod_lectura_critica_pnal_sbpro = mod_lectura_critica_pnal,
```


BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
mod_competen_ciudadana_pnal_sbpro = mod_competen_ciudadana_pnal,  
mod_comuni_escrita_pnal_sbpro = mod_comuni_escrita_pnal,  
percentil_global_sbpro = percentil_global,  
)
```

Unir las tres bases mediante la tabla de cruce

```
base_final <- cruce_saber11_saberpro %>%  
  left_join(  
    saber11_final,  
    by = c("estu_consecutivo_sb11", "periodo_sb11")  
  ) %>%  
  left_join(  
    saberpro_final,  
    by = c("estu_consecutivo_sbpro", "periodo_sbpro")  
  ) %>%  
  distinct()
```

Verificación aplicada:

Se verificó que las variables seleccionadas fueran renombradas correctamente, conservando sin modificaciones los identificadores necesarios para realizar el cruce. Antes y después de la unión se revisaron las dimensiones de las bases, coincidencias entre identificadores, registros duplicados y posibles pérdidas de información.

Resultado:

Propuesta aceptada. Se logró preparar las bases diferenciando las variables de Saber 11 y Saber Pro y realizar su unión con la base de cruce. Las verificaciones permitieron comprobar la estructura de la base resultante y detectar posibles duplicados o pérdidas de registros, dejando la información lista para las siguientes etapas del proyecto

FASE 7. LIMPIEZA Y ESTANDARIZACIÓN DE SABER 11

INTERACCIÓN 8

Objetivo de la consulta: Limpiar y estandarizar las variables categóricas seleccionadas de Saber 11, corrigiendo inconsistencias de escritura y unificando categorías que representen el mismo concepto, sin eliminar registros ni modificar los valores faltantes.

PROMPT

Okey Chat, ya tenemos la base final con las tres bases unidas. Ahora quiero comenzar con la limpieza de las variables categóricas de Saber 11, porque al revisar los datos encontré inconsistencias en algunas respuestas. Por ejemplo, en el departamento aparecen valores como BOGOTA y BOGOTÁ, que representan lo mismo.

Quiero limpiar estas variables:

estu_depto_reside_sb11, cole_bilingue_sb11, cole_area_ubicacion_sb11, cole_calendario_sb11, cole_naturaleza_sb11, fami_educacionmadre_sb11, fami_educacionpadre_sb11, fami_estratovivienda_sb11, fami_tienecomputador_sb11 y fami_tieneinternet_sb11.

Primero quiero que revises los valores únicos que tiene cada variable y, con base en las respuestas reales de la base y en el diccionario, identifiques inconsistencias de escritura, mayúsculas, tildes, espacios o categorías equivalentes. No debemos asumir que dos categorías son iguales sin comprobarlo.

Por ejemplo, en fami_estratovivienda_sb11, si aparecen estrato 0 y sin estrato, quiero unificarlos en una sola categoría porque representan lo mismo. Haz lo mismo con las demás variables cuando exista una equivalencia comprobada.

Necesito un código organizado y reproducible que realice estas correcciones y que, antes y después de la limpieza, muestre las categorías existentes para poder verificar los cambios. No elimines registros ni modifiques valores NA. Si encuentras categorías cuya equivalencia no sea clara, indícamelas antes de modificarlas.

Fecha: 17 agosto

Etapas: Fase 7 Limpieza y estandarización de saber 11

Respuesta obtenida:

```
base_final_limpia <- base_final %>%
  mutate(
    # departamento reside
    estu_depto_reside_sb11 = case_when(
      estu_depto_reside_sb11 == "BOGOTA" ~ "BOGOTÁ",
      TRUE ~ estu_depto_reside_sb11
    ),
    # Colegio bilingüe
    cole_bilingue_sb11 = case_when(
```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
cole_bilingue_sb11 == "S" ~ "S",  
cole_bilingue_sb11 == "N" ~ "N",  
TRUE ~ NA_character_  
)
```

```
# Área del colegio  
cole_area_ubicacion_sb11 = case_when(  
  cole_area_ubicacion_sb11 %in% c("URBANO", "URBANA") ~ "URBANA",  
  cole_area_ubicacion_sb11 == "RURAL" ~ "RURAL",  
  TRUE ~ NA_character_  
)
```

```
# Calendario  
cole_calendario_sb11 = case_when(  
  cole_calendario_sb11 %in% c("A", "B", "OTRO") ~ cole_calendario_sb11,  
  TRUE ~ NA_character_  
)
```

```
# Naturaleza del colegio  
cole_naturaleza_sb11 = case_when(  
  cole_naturaleza_sb11 %in% c("OFICIAL", "NO OFICIAL") ~ cole_naturaleza_sb11,  
  TRUE ~ NA_character_  
)
```

```
# Educación de la madre  
fami_educacionmadre_sb11 = case_when(  
fami_educacionmadre_sb11 %in% c(  
  "Secundaria (Bachillerato) completa",  
  "Educación profesional completa",  
  "Técnica o tecnológica completa",  
  "Secundaria (Bachillerato) incompleta",  
  "Primaria completa",  
  "Postgrado",  
  "Primaria incompleta",  
  "Educación profesional incompleta",  
  "Técnica o tecnológica incompleta",  
  "Ninguno"  
) ~ fami_educacionmadre_sb11,  
TRUE ~ NA_character_  
)
```

```
# Educación del padre  
fami_educacionpadre_sb11 = case_when(  
fami_educacionpadre_sb11 %in% c(  
  "Secundaria (Bachillerato) completa",  
  "Educación profesional completa",  
  "Secundaria (Bachillerato) incompleta",  

```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
"Técnica o tecnológica completa",
"Primaria incompleta",
"Primaria completa",
"Postgrado",
"Educación profesional incompleta",
"Técnica o tecnológica incompleta",
"Ninguno"
) ~ fami_educacionpadre_sb11,
TRUE ~ NA_character_
),

# Estrato
fami_estratovivienda_sb11 = case_when(
  fami_estratovivienda_sb11 %in% c(
    "Estrato 1",
    "Estrato 2",
    "Estrato 3",
    "Estrato 4",
    "Estrato 5",
    "Estrato 6",
    "Sin Estrato"
  ) ~ fami_estratovivienda_sb11,
  TRUE ~ NA_character_
),

# Computador
fami_tienecomputador_sb11 = case_when(
  fami_tienecomputador_sb11 %in% c("Si", "No") ~ fami_tienecomputador_sb11,
  TRUE ~ NA_character_
),

# Internet
fami_tieneinternet_sb11 = case_when(
  fami_tieneinternet_sb11 %in% c("Si", "No") ~ fami_tieneinternet_sb11,
  TRUE ~ NA_character_
)
)
```

Verificación aplicada:

Se revisaron los valores únicos de cada variable antes de la limpieza y se compararon con el diccionario correspondiente. Después de aplicar las correcciones, se volvieron a revisar las categorías para comprobar que las inconsistencias identificadas fueran corregidas y que los valores NA se conservaran.

Resultado:

Propuesta aceptada. Se realizó la estandarización de las variables categóricas de Saber 11, corrigiendo inconsistencias y unificando categorías equivalentes previamente verificadas. La comparación de las categorías antes y después permitió comprobar los cambios realizados sin alterar los registros ni los valores faltantes.

FASE 7. LIMPIEZA Y ESTANDARIZACIÓN DE SABER PRO

INTERACCIÓN 9

Objetivo de la consulta: Limpiar y estandarizar las variables categóricas de Saber Pro, prestando especial atención a las inconsistencias del núcleo de pregrado, y validar los cinco puntajes para conservar únicamente estudiantes con valores numéricos, enteros y entre 0 y 500.

PROMPT

Okey Chat, ahora quiero hacer el mismo proceso de limpieza, pero con las variables categóricas de Saber Pro. Las variables que vamos a trabajar son: departamento donde reside, género, educación de la madre, educación del padre, estrato, computador e internet. Recuerda que en la base final terminan en `_sbpro`.

También quiero hacer una limpieza más cuidadosa de la variable núcleo de pregrado, porque encontré inconsistencias como `disenio` y `diseño` que representan la misma categoría. Quiero que revises los valores existentes y, con base en ellos, unifiques errores de escritura, tildes, mayúsculas, espacios y categorías que claramente representen lo mismo. No inventes categorías ni unifiques valores si no es evidente que significan lo mismo.

Además, quiero limpiar los cinco puntajes de Saber Pro. Solo deben conservarse los estudiantes cuyos cinco puntajes sean numéricos, enteros y estén entre 0 y 500, ambos valores incluidos. Si al menos uno de los cinco puntajes no cumple alguno de estos criterios, se debe eliminar toda la fila del estudiante.

Necesito un código organizado y reproducible que haga todo esto y que incluya verificaciones antes y después: categorías de las variables, cantidad de registros, estudiantes eliminados por los puntajes y comprobación de que los cinco puntajes finales cumplen los criterios. Los valores NA en los puntajes deben considerarse inválidos y provocar la eliminación de la fila. No realices otras modificaciones que no sean las mencionadas.

Fecha: 18 agosto 2026

Etapas: Fase 7 Limpieza y estandarización de saber pro

Respuesta obtenida:

```
base_final_limpia <- base_final_limpia %>%
  mutate(
```

```
  # =====
  # DEPARTAMENTO DONDE RESIDE - SABER PRO
  # =====
```

```
  estu_depto_reside_sbpro = case_when(
    estu_depto_reside_sbpro == "BOGOTA" ~ "BOGOTÁ",
    TRUE ~ estu_depto_reside_sbpro
  ),
```

```
  # =====
```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

GÉNERO - SABER PRO

=====

```
estu_genero_sbpro = case_when(  
  estu_genero_sbpro %in% c("F", "M") ~ estu_genero_sbpro,  
  TRUE ~ NA_character_  
)
```

=====

EDUCACIÓN DE LA MADRE - SABER PRO

=====

```
fami_educacionmadre_sbpro = case_when(  
  fami_educacionmadre_sbpro %in% c(  
    "Secundaria (Bachillerato) completa",  
    "Educación profesional completa",  
    "Técnica o tecnológica completa",  
    "Secundaria (Bachillerato) incompleta",  
    "Primaria completa",  
    "Postgrado",  
    "Primaria incompleta",  
    "Educación profesional incompleta",  
    "Técnica o tecnológica incompleta",  
    "Ninguno"  
  ) ~ fami_educacionmadre_sbpro,  
  TRUE ~ NA_character_  
)
```

=====

EDUCACIÓN DEL PADRE - SABER PRO

=====

```
fami_educacionpadre_sbpro = case_when(  
  fami_educacionpadre_sbpro %in% c(  
    "Secundaria (Bachillerato) completa",  
    "Educación profesional completa",  
    "Técnica o tecnológica completa",  
    "Secundaria (Bachillerato) incompleta",  
    "Primaria completa",  
    "Postgrado",  
    "Primaria incompleta",  
    "Educación profesional incompleta",  
    "Ninguno"  
  ) ~ fami_educacionpadre_sbpro,  
  TRUE ~ NA_character_
```

),

=====

ESTRATO - SABER PRO

=====

```
fami_estratovivienda_sbpro = case_when(
  fami_estratovivienda_sbpro == "Estrato 1" ~ "Estrato 1",
  fami_estratovivienda_sbpro == "Estrato 2" ~ "Estrato 2",
  fami_estratovivienda_sbpro == "Estrato 3" ~ "Estrato 3",
  fami_estratovivienda_sbpro == "Estrato 4" ~ "Estrato 4",
  fami_estratovivienda_sbpro == "Estrato 5" ~ "Estrato 5",
  fami_estratovivienda_sbpro == "Estrato 6" ~ "Estrato 6",
  fami_estratovivienda_sbpro == "Sin Estrato" ~ "Sin Estrato",
  fami_estratovivienda_sbpro == "Estrato 0" ~ "Sin Estrato",
  TRUE ~ NA_character_
),
```

COMPUTADOR - SABER PRO

```
fami_tienecomputador_sbpro = case_when(
  fami_tienecomputador_sbpro %in% c("Si", "No") ~
    fami_tienecomputador_sbpro,
  TRUE ~ NA_character_
),
```

INTERNET - SABER PRO

```
fami_tieneinternet_sbpro = case_when(
  fami_tieneinternet_sbpro %in% c("Si", "No") ~
    fami_tieneinternet_sbpro,
  TRUE ~ NA_character_
)
)
```

LIMPIEZA DEL NÚCLEO DE PREGRADO - SABER PRO

```
base_final_limpia <- base_final_limpia %>%
mutate(
  estu_nucleo_pregrado_sbpro = stri_trans_general(
    estu_nucleo_pregrado_sbpro,
    "Latin-ASCII"
  ),
```


BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
estu_nucleo_pregrado_sbpro = case_when(  
  
  # Faltantes y categorías sin información  
  estu_nucleo_pregrado_sbpro %in% c(  
    "SIN CLASIFICAR",  
    "SIN ESPECIFICAR"  
  ) ~ NA_character_,  
  
  # Correcciones de escritura  
  estu_nucleo_pregrado_sbpro == "DISEÑO" ~  
    "DISENO",  
  
  estu_nucleo_pregrado_sbpro ==  
    "ATES PLASTICAS, VISUALES Y AFINES" ~  
    "ARTES PLASTICAS, VISUALES Y AFINES",  
  
  estu_nucleo_pregrado_sbpro ==  
    "INGENIERIA ADMINISTRATIVA Y AFINES" ~  
    "INGENIERIA ADMINISTRATIVA Y AFINES",  
  
  TRUE ~ estu_nucleo_pregrado_sbpro  
)  
)  
  
# LIMPIEZA DE PUNTAJES - SABER PRO  
# Se conservan únicamente estudiantes cuyos cinco puntajes:  
# 1. Sean numéricos  
# 2. Sean valores enteros  
# 3. Estén entre 0 y 300  
#  
# Si alguno de los cinco puntajes incumple el criterio,  
# se elimina toda la fila del estudiante.  
  
base_final_limpia <- base_final_limpia %>%  
  filter(  
    !is.na(mod_competen_ciudadana_punt_sbpro),  
    !is.na(mod_comuni_escrita_punt_sbpro),  
    !is.na(mod_ingles_punt_sbpro),  
    !is.na(mod_lectura_critica_punt_sbpro),  
    !is.na(mod_razona_cuantitat_punt_sbpro),  
  
    mod_competen_ciudadana_punt_sbpro >= 0,  
    mod_competen_ciudadana_punt_sbpro <= 300,  
    mod_competen_ciudadana_punt_sbpro == floor(mod_competen_ciudadana_punt_sbpro),  
  
    mod_comuni_escrita_punt_sbpro >= 0,  
    mod_comuni_escrita_punt_sbpro <= 300,
```

BITÁCORA DE USO DE INTELIGENCIA ARTIFICIAL

```
mod_comuni_escrita_punt_sbpro == floor(mod_comuni_escrita_punt_sbpro),  
  
mod_ingles_punt_sbpro >= 0,  
mod_ingles_punt_sbpro <= 300,  
mod_ingles_punt_sbpro == floor(mod_ingles_punt_sbpro),  
  
mod_lectura_critica_punt_sbpro >= 0,  
mod_lectura_critica_punt_sbpro <= 300,  
mod_lectura_critica_punt_sbpro == floor(mod_lectura_critica_punt_sbpro),  
  
mod_razona_cuantitat_punt_sbpro >= 0,  
mod_razona_cuantitat_punt_sbpro <= 300,  
mod_razona_cuantitat_punt_sbpro == floor(mod_razona_cuantitat_punt_sbpro)  
)
```

Verificación aplicada:

Se revisaron los valores únicos de las variables categóricas y se compararon las categorías equivalentes antes de realizar las correcciones. Para los puntajes, se verificó que cada estudiante tuviera los cinco valores numéricos, enteros y dentro del rango establecido. También se comparó el número de registros antes y después del proceso.

Resultado:

Propuesta aceptada. Se realizó la limpieza y estandarización de las variables categóricas de Saber Pro y se corrigieron las inconsistencias comprobadas en el núcleo de pregrado. Además, se eliminaron las filas de estudiantes que no cumplían los criterios establecidos para los cinco puntajes, dejando una base validada para continuar con el análisis.
