



ACREDITADA
POR ALTA CALIDAD

UNIVERSIDAD DEL MAGDALENA

PROYECTO 1:

**CONSTRUCCIÓN DE UN PANEL LONGITUDINAL MULTI-COHORTE SABER
11- SABER PRO (2014–2025), REPRODUCIBLE Y AUTOMATIZADO**

PRESENTADO A:

ENRIQUE J. DE LA HOZ DOMÍNGUEZ

INTEGRANTES:

CAMILO HENRIQUEZ NOGUERA

VALERIA GUTIÉRREZ NÚÑEZ

LISNAY MENDOZA MOLINA

FACULTAD DE INGENIERÍAS

PROGRAMA DE INGENIERIA INDUSTRIAL

2026

1. Resumen

El presente proyecto tuvo como propósito construir un panel longitudinal multi-cohorte a partir de la integración de los microdatos de las pruebas Saber 11 y Saber Pro, con el fin de relacionar el desempeño de los estudiantes en diferentes etapas de su trayectoria académica. Para ello, se desarrolló un proceso estructurado de importación, revisión, limpieza, estandarización, homologación, consolidación y posterior vinculación de las bases de datos, utilizando RStudio como herramienta principal y manteniendo las transformaciones registradas mediante código para garantizar la trazabilidad y reproducibilidad del procedimiento.

El alcance del proyecto comprendió los registros disponibles de Saber 11 correspondientes al periodo 2010-I a 2025-II y de Saber Pro correspondientes al periodo 2014-2024. La integración se realizó inicialmente de manera independiente para cada prueba y posteriormente se efectuó la vinculación entre ambas fuentes mediante los identificadores disponibles y un criterio temporal de inclusión de mínimo dos años entre la presentación de Saber 11 y Saber Pro. Este criterio permitió establecer correspondencias temporalmente coherentes entre ambas evaluaciones y reducir posibles emparejamientos inadecuados.

Como resultado del proceso, se obtuvieron 1.389.383 registros vinculados, correspondientes a 26 cohortes con vinculación efectiva, a partir de un universo de 10.682.841 registros de referencia, lo que representa una tasa global de vinculación aproximada del 13,01%. La cobertura no fue uniforme entre las cohortes: mientras los periodos comprendidos entre 2010-I y 2022-II presentaron registros vinculados, las cohortes posteriores no pudieron ser emparejadas debido a la disponibilidad temporal de las bases utilizadas. Por tanto, la tasa global debe interpretarse considerando las diferencias de cobertura entre periodos y no como una medida uniforme del comportamiento de todos los estudiantes.

2. Fuentes de datos

Para el desarrollo del proyecto se utilizaron las bases de datos completas correspondientes a las pruebas Saber 11 y Saber Pro, a partir de las cuales se realizó posteriormente el proceso de cruce y vinculación de los registros. Los archivos fueron procesados mediante RStudio, conservando las fuentes originales y realizando las transformaciones necesarias mediante código.

Para Saber 11 se dispuso de información correspondiente a los periodos comprendidos entre 2012-I y 2025-II, mientras que para Saber Pro se contó con información disponible entre 2014 y 2024. Esta diferencia en la cobertura temporal fue considerada durante el proceso de vinculación, debido a que condiciona las cohortes que pueden ser relacionadas entre ambas pruebas.

Debido al volumen de información manejado, en este informe se presenta un inventario resumido de los archivos utilizados, en lugar de detallar individualmente

cada archivo. El inventario permite identificar la prueba, el periodo, la cantidad de registros, el numero de variables, la fecha de descarga, el diccionario consultado y la base de datos origen. De esta manera, se conserva la trazabilidad de las fuentes empleadas sin sobrecargar la presentación del informe.

2.1. Inventarios de archivos

La Tabla 1 presenta el inventario resumido de las fuentes utilizadas para la construcción de la base. La columna Fuente identifica la base de datos origen de cada conjunto de registros, mientras que el periodo permite ubicar temporalmente la información dentro del proceso de integración.

Prueba	Periodo de la base de datos	Archivo utilizado	Registros	Variables	Fecha de descarga	Diccionario consultado
Saber 11	20101	Base de datos 2014	4772	43	10/08/2026	Diccionario Saber 11
Saber 11	20102	Base de datos 2014	106036	43	10/08/2026	Diccionario Saber 11
Saber 11	20111	Base de datos 2014	7497	43	10/08/2026	Diccionario Saber 11
Saber 11	20112	Base de datos 2014	143222	43	10/08/2026	Diccionario Saber 11
Saber 11	20121	Base de datos 2014	10455	48	10/08/2026	Diccionario Saber 11
Saber 11	20122	Base de datos 2014	155598	48	10/08/2026	Diccionario Saber 11
Saber 11	20131	Base de datos 2014	10586	48	10/08/2026	Diccionario Saber 11
Saber 11	20132	Base de datos 2014	155076	48	10/08/2026	Diccionario Saber 11
Saber 11	20141	Base de datos 2014	10322	48	10/08/2026	Diccionario Saber 11
Saber 11	20142	Base de datos 2014	158797	51	10/08/2026	Diccionario Saber 11
Saber 11	20151	Base de datos 2014	10163	51	10/08/2026	Diccionario Saber 11
Saber 11	20152	Base de datos 2014	150215	51	10/08/2026	Diccionario Saber 11
Saber 11	20161	Base de datos 2014	9317	57	10/08/2026	Diccionario Saber 11
Saber 11	20162	Base de datos 2014	145152	57	10/08/2026	Diccionario Saber 11
Saber 11	20171	Base de datos 2014	8905	57	10/08/2026	Diccionario Saber 11
Saber 11	20172	Base de datos 2014	123472	57	10/08/2026	Diccionario Saber 11
Saber 11	20181	Base de datos 2014	7607	57	10/08/2026	Diccionario Saber 11
Saber 11	20182	Base de datos 2014	95293	57	10/08/2026	Diccionario Saber 11
Saber 11	20191	Base de datos 2014	5995	57	10/08/2026	Diccionario Saber 11
Saber 11	20192	Base de datos 2014	54000	57	10/08/2026	Diccionario Saber 11
Saber 11	20201	Base de datos 2014	3081	57	10/08/2026	Diccionario Saber 11
Saber 11	20202	Base de datos 2014	12555	57	10/08/2026	Diccionario Saber 11
Saber 11	20211	Base de datos 2014	418	57	10/08/2026	Diccionario Saber 11
Saber 11	20212	Base de datos 2014	790	57	10/08/2026	Diccionario Saber 11
Saber 11	20221	Base de datos 2014	2	56	10/08/2026	Diccionario Saber 11
Saber 11	20222	Base de datos 2014	57	56	10/08/2026	Diccionario Saber 11
Saber Pro	20153	Base de datos 2014	2	38	12/08/2026	Diccionario Saber Pro
Saber Pro	20163	Base de datos 2014	93962	50	12/08/2026	Diccionario Saber Pro
Saber Pro	20173	Base de datos 2014	113495	50	12/08/2026	Diccionario Saber Pro
Saber Pro	20182	Base de datos 2014	900	50	12/08/2026	Diccionario Saber Pro
Saber Pro	20183	Base de datos 2014	127741	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20184	Base de datos 2014	217	50	12/08/2026	Diccionario Saber Pro
Saber Pro	20194	Base de datos 2014	1269	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20195	Base de datos 2014	159345	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20196	Base de datos 2014	138	50	12/08/2026	Diccionario Saber Pro
Saber Pro	20202	Base de datos 2014	334	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20203	Base de datos 2014	162155	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20212	Base de datos 2014	170955	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20213	Base de datos 2014	1099	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20222	Base de datos 2014	67962	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20223	Base de datos 2014	382	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20225	Base de datos 2014	94604	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20226	Base de datos 2014	817	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20231	Base de datos 2014	98226	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20232	Base de datos 2014	1360	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20233	Base de datos 2014	81676	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20234	Base de datos 2014	793	57	12/08/2026	Diccionario Saber Pro
Saber Pro	20241	Base de datos 2014	120186	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20242	Base de datos 2014	1692	56	12/08/2026	Diccionario Saber Pro

Saber Pro	20243	Base de datos 2014	88823	56	12/08/2026	Diccionario Saber Pro
Saber Pro	20244	Base de datos 2014	1150	56	12/08/2026	Diccionario Saber Pro

Tabla 1: Inventario resumido de las bases de datos utilizadas

El inventario evidencia que la estructura de las bases presentó variaciones entre los diferentes periodos. En Saber 11, por ejemplo, se observa un cambio en el número de variables disponibles, pasando de 43 variables en los primeros periodos a 48 y posteriormente 51 en algunos años. De igual forma, el número de registros presenta diferencias importantes entre periodos. Estas variaciones hicieron necesario revisar y homologar las estructuras antes de realizar la consolidación y los cruces entre las pruebas.

Por tanto, la tabla constituye una síntesis del inventario de las bases completas utilizadas, y no una reducción de los datos empleados en el procesamiento. La información completa de los archivos fue conservada durante las etapas de limpieza, homologación, consolidación y posterior vinculación.

3. Estrategia de integración

La estrategia de las bases de Saber 11 Y saber pro se realizó de manera progresiva, partiendo de las bases previamente organizadas y consolidadas para cada prueba. Antes de efectuar la integración, las variables fueron diferenciadas según su fuente mediante la incorporación de los prefijos “sb11” para las variables provenientes de Saber 11 y “sbpro” para las variables provenientes de Saber Pro. Esta modificación tuvo como finalidad identificar claramente el origen de cada variable en la base resultante y evitar confusiones entre variables provenientes de las dos pruebas.

3.1. Tipo de unión y criterio de inclusión

El tipo de unión utilizado para integrar la información fue “left_join”. Esta operación permitió conservar los registros de la base tomada como referencia y añadir la información correspondiente de la otra prueba cuando se encontraba una coincidencia de acuerdo con los criterios definidos para el cruce.

La utilización de “left_join” permitió mantener la estructura y el universo de registros de la base de referencia, mientras que los registros de la otra prueba se incorporaron únicamente cuando cumplían las condiciones necesarias para establecer la correspondencia. De esta manera, los casos sin coincidencia no fueron eliminados de la base de referencia, sino que permanecieron en ella sin la información correspondiente de la otra prueba.

3.2. Consistencia temporal

Como criterio de consistencia temporal se estableció un rezago mínimo de dos años entre Saber 11 y Saber Pro. Este criterio buscó garantizar una secuencia temporal coherente entre ambas evaluaciones, considerando que Saber 11 corresponde a una etapa previa de la trayectoria educativa y Saber pro a una etapa posterior.

El rezago de dos años se utilizó como una regla de inclusión y control temporal, por lo que o significa que todos los estudiantes debieran presentar Saber Pro exactamente dos años después de Saber 11. Su finalidad fue reducir vinculaciones temporalmente inadecuadas y establecer una correspondencia razonable entre las dos etapas de evaluación.

3.3. Tratamiento de duplicados y presentaciones múltiples

Durante el proceso de integración se consideró el posible efecto de los registros duplicados y de las presentaciones múltiples en cualquiera de las dos pruebas. Esta revisión fue necesaria debido a que la existencia de más de un registro asociado a un mismo estudiante puede generar múltiples coincidencias durante un “left_join” y, en consecuencia, aumentar inesperadamente el número de observaciones de la base resultante.

Para controlar este comportamiento, los duplicados fueron eliminados en el momento de realizar la unión de las bases, de manera que cada estudiante quedara representado una sola vez en el resultado final.

Este procedimiento permitió controlar la multiplicación de registros que podría generarse cuando un mismo estudiante presentara más de una observación en alguna de las pruebas. La eliminación de duplicados contribuyó a mantener la consistencia de la base integrada y a evitar que un estudiante tuviera un peso mayor al esperado en los análisis posteriores.

3.4. Flujo de datos

El proceso general de integración siguió la secuencia que se ve en la figura 1:




Figura 1: Diagrama de flujo de datos

4. Limpieza y estandarización

La limpieza de los datos tuvo como propósito resolver los problemas que pudieran impedir la comparación o vinculación correcta de las observaciones, sin recurrir a la eliminación indiscriminada de registros. Cada decisión se tomó después de inspeccionar la estructura de los datos y contrastarla con los diccionarios correspondientes a cada periodo, de manera que las transformaciones aplicadas pudieran justificarse y no solo ejecutarse sin errores. A continuación, se describen los problemas identificados, agrupados por tipo, y el criterio utilizado para resolver cada uno.

4.1. Diferencias en nombres y tipos de variables

Uno de los problemas más frecuentes fue que una misma variable podía aparecer bajo nombres distintos según el periodo. Para resolverlo, se estableció una denominación común dentro de la base consolidada, pero únicamente en los casos donde la documentación permitía comprobar que ambas variables representaban el mismo concepto; el criterio de homologación no se basó en la similitud del nombre, sino en la coincidencia de la definición, las categorías y la estructura reportada para cada periodo.

De forma complementaria, se revisaron los tipos de datos de las variables. Algunas variables que conceptualmente correspondían a valores numéricos se encontraban almacenadas como texto, debido a códigos especiales, separadores u otras particularidades propias de cada archivo. Por esta razón, antes de ejecutar cualquier operación de unión o cálculo se verificó que los tipos de datos fueran compatibles entre las bases involucradas, evitando así errores silenciosos que no se manifiestan como fallos de ejecución, pero sí afectan el resultado final.

4.2. Valores faltantes

Los valores faltantes se revisaron mediante conteos por variable, utilizando principalmente la función `colSums(is.na(base_final_limpia))`. El objetivo de este paso no fue depurar automáticamente la base, sino dimensionar la magnitud del problema antes de decidir cómo tratarlo.

Se descartó como regla general la eliminación automática de todos los registros con NA, debido a que esta práctica reduciría innecesariamente la cobertura de la base. En su lugar, cada variable con valores faltantes fue evaluada de manera individual, considerando su naturaleza y el propósito del análisis en el que sería utilizada, de forma que la decisión respondiera al contexto de cada caso y no a la regla uniforme aplicada sin distinción.

4.3. Diferencias de categorías

Las categorías de las variables también fueron revisadas entre periodos para verificar su correspondencia. Cuando una variable presentaba diferencias en su codificación, se consultó el diccionario antes de realizar cualquier homologación,

dado que dos variables con nombres similares no necesariamente representan el mismo concepto. La equivalencia entre categorías se estableció considerando conjuntamente el nombre, la definición y las categorías documentadas para cada periodo, replicando el mismo principio de verificación aplicado a los nombres y tipos de variables.

4.4. Puntajes Saber Pro-2014-2015

El caso que requirió mayor atención durante el proceso de limpieza correspondió a los puntajes de Saber pro de los periodos 2014 y 2015. Durante la inspección se identificó que estos resultados se encontraban representados con decimales, mientras que en los periodos posteriores los puntajes se presentaban bajo una escala o formato distinto. Esta diferencia no era evidente a simple vista y solo se detectó al comparar la estructura de la variable entre periodos.

Frente a esta situación, se descartó de entrada aplicar un redondeo automático, dado que una corrección de ese tipo podía alterar el significado original del puntaje sin que existiera evidencia suficiente para respaldarla. En su lugar, se siguió un procedimiento de verificación den tres pasos: primero se revisó el tipo de variable y los valores efectivamente observados; segundo, se contrastó esta información con a la documentación oficial correspondiente a cada periodo; y solo después de comprobar que la transformación no modificaba el significado del puntaje se consideró valido cualquier ajuste sobre los datos.

Con base en esta verificación, el caso se trató como una diferencia de representación o formato, y no como un error numérico que debiera corregirse de manera directa. Esta distinción es relevante porque tratar el problema como un simple error habría llevado a una corrección apresurada, mientras que abordarlo como una diferencia de representación obligó a documentar el criterio y a preservar la trazabilidad de la decisión.

4.5. Errores durante el procesamiento

Durante la ejecución del código se presentó el error “object 'datos_genero' not found”, el cual indicaba que se estaba intentando utilizar un objeto que no había sido creado o cargado en el entorno de trabajo en ese momento. La solución consistió en revisar el orden de ejecución del script e identificar cuales objetos habían sido efectivamente generados en los pasos anteriores, antes de continuar con las transformaciones siguientes. Este incidente, aunque puntual, evidencio la importancia de mantener una secuencia de ejecución ordenada y reproducible a lo largo de todo el flujo de trabajo.

4.6. Problemas de memoria y volumen de información

El tamaño de las bases de datos generó dificultades de memoria y procesamiento, particularmente al intentar cargar o transformar simultáneamente grandes volúmenes de información. Como respuesta, se optó por un procesamiento progresivo, seleccionando únicamente las variables relevantes para cada etapa y

evitando operaciones innecesariamente amplias sobre la totalidad de los datos. Esta decisión no solo redujo la carga computacional, sino que también facilitó identificar en qué etapa específica se originaba un error cuando este ocurría, algo que habría sido más difícil de aislar dentro de una transformación única sobre toda la base.

5. Validación y calidad

La validación se desarrolló como una etapa transversal del proyecto. El hecho de que el código pudiera ejecutarse sin errores no se consideró suficiente para garantizar la calidad de la base; por ello se realizaron controles de estructura, dimensiones, faltantes, categorías, tipos de datos y resultados de las uniones a lo largo de todo el proceso.

5.1. Controles realizados

Entre los principales controles se encuentran:

- Revisión de dimensiones mediante `dim()`;
- Revisión de nombres mediante `names()`;
- Inspección de estructuras mediante `glimpse()`;
- Conteo de valores faltantes mediante `colSums(is.na())`;
- Revisión de frecuencias y categorías;
- Contraste con los diccionarios oficiales;
- Verificación de tipos de datos en las llaves de vinculación.

Estos controles permitieron comprobar que las transformaciones no alteraran de manera inesperada la estructura de los datos.

5.2. Validación de las uniones

Para validar las uniones se compararon los números de observaciones antes y después de cada operación, y se revisaron tanto las coincidencias como los registros que no encontraron correspondencia. Esta comparación permite distinguir entre una pérdida de registros explicable por las condiciones de vinculación y una pérdida ocasionada por errores en las llaves, los tipos de datos o las transformaciones. También se prestó especial atención a los duplicados, dado que una llave con múltiples coincidencias puede multiplicar filas durante un join sin que R reporte ningún error.

5.3. Matriz de cobertura de cohortes

La cobertura no puede evaluarse únicamente a partir de la tasa global del 13,01 %, ya que esta cifra agregada oculta un patrón muy marcado por cohorte.

cohorte_saber11	periodo_saberpro_esperado	registro_saber11	registros_vinculados	tasa_vinculacion	cobertura
20101	2012	124682	4772	3,83	Parcial
20102	2012	586964	106036	18,07	Parcial
20111	2013	86858	7497	8,63	Parcial

20112	2013	564392	143222	25,38	Parcial
20121	2014	95946	10455	10,9	Parcial
20122	2014	575646	155598	27,01	Parcial
20131	2015	84957	10586	12,46	Parcial
20132	2015	573659	155076	27,03	Parcial
20141	2016	88343	10322	11,68	Parcial
20142	2016	574259	158797	27,65	Parcial
20151	2017	108259	10163	9,39	Parcial
20152	2017	574158	150215	26,16	Parcial
20161	2018	74224	9317	12,55	Parcial
20162	2018	589593	145152	24,62	Parcial
20171	2019	85149	8905	10,46	Parcial
20172	2019	590996	123472	20,89	Parcial
20181	2020	65854	7607	11,55	Parcial
20182	2020	609136	95293	15,64	Parcial
20191	2021	66104	5995	9,07	Parcial
20192	2021	614789	54000	8,78	Parcial
20201	2022	46221	3081	6,67	Parcial
20202	2022	556891	12555	2,25	Parcial
20211	2023	58708	418	0,71	Parcial
20212	2023	606030	790	0,13	Parcial
20221	2024	73795	2	0	Parcial
20222	2024	589183	57	0,01	Parcial
20231	2025	77555	0	0	Sin vinculación
20232	2025	602093	0	0	Sin vinculación
20241	2026	84072	0	0	Sin vinculación
20242	2026	592436	0	0	Sin vinculación
20251	2027	85678	0	0	Sin vinculación
20252	2027	576211	0	0	Sin vinculación

Tabla 2: Matriz de cobertura de cohortes

La tasa de vinculación presenta un comportamiento definido: aumenta hasta alcanzar sus valores más altos entre 2014-II y 2016-II y posteriormente disminuye hasta llegar a 0 % desde 2023-I. Este comportamiento está relacionado principalmente con la disponibilidad temporal de los datos y con el momento en que los estudiantes presentan Saber Pro.

A partir de 2023-I, las cohortes de Saber 11 tienen un periodo esperado de presentación de Saber Pro posterior a 2024, por lo que no pueden contar con registros vinculados. Estas seis cohortes reúnen 2.018.045 registros, equivalentes al 18,9 % del universo, y su tasa de 0 % corresponde al límite de información disponible y no a una falla del procedimiento.

Por otro lado, las cohortes entre 2019-I y 2022-II presentan tasas bajas, entre 0,01 % y 9,07 %. Esto se relaciona con que una parte importante de los estudiantes vinculados presenta Saber Pro entre cinco y seis años después de Saber 11. Como la información disponible llega únicamente hasta 2024, estas cohortes aún tienen una ventana de observación limitada. En conjunto, estas dos situaciones representan 4.552.868 de los 9.293.458 registros no vinculados, cerca del 49 % de la pérdida total.

También se observa que, dentro de un mismo año, las cohortes del periodo I suelen presentar tasas de vinculación menores que las del periodo II. Por ejemplo, en 2010 las tasas fueron de 3,83 % y 18,07 %, respectivamente. Además, las cohortes I son entre cinco y ocho veces más pequeñas. Este comportamiento podría indicar diferencias entre las poblaciones de ambos periodos.

5.4. Distribución del rezago

rezago	registros_vinculados	porcentaje
2	1835	0,13
3	10184	0,73
4	143999	10,36
5	422522	30,41
6	316778	22,8
7	190370	13,7
8	116812	8,41
9	74312	5,35
10	47117	3,39
11	30077	2,16
12	18970	1,37
13	11114	0,8
14	5193	0,37

Tabla 3: Distribución del rezago

La tabla 3 nos permite entender por qué el truncamiento afecta de forma tan marcada a las cohortes recientes. El rezago no se concentra en el mínimo de dos años establecido como criterio de inclusión, sino en un rango bastante más amplio. Vemos que apenas el 0,86% de los vinculados presentan un rezago de 2 o 3 años, mientras que la mayor parte se ubica entre 5 y 6 años, con unos porcentajes de 30,41% y 22,8% respectivamente, es decir, más de la mitad de todos los vinculados.

Este resultado es coherente con la duración típica de un programa universitario en Colombia y confirma que el rezago mínimo de dos años funcionó como un filtro de exclusión de emparejamientos temporalmente inválidos, y no como una descripción del comportamiento típico de los estudiantes.

5.5. Interpretación de las pérdidas de vinculación

La pérdida de registros no debe interpretarse automáticamente como una falla del procedimiento. Para determinar su origen, es necesario distinguir entre las coincidencias encontradas que fueron posteriormente descartadas por criterios de calidad y consistencia, y los registros para los cuales nunca se encontró una coincidencia.

Antes de aplicar el rezago mínimo de dos años y los criterios de validación de puntajes, el cruce por identificador produjo 1.617.405 coincidencias entre Saber 11 y Saber Pro. De estas, 1.389.383 registros cumplieron finalmente los criterios

establecidos. Los 228.022 registros restantes, equivalentes al 14,1 % de las coincidencias brutas y al 2,4 % de la pérdida total, fueron descartados por presentar una secuencia temporal inválida o valores de Saber Pro que, incluso después de las correcciones realizadas durante la limpieza, continuaban siendo inconsistentes o inválidos. Por tanto, la limpieza fue conservadora: se corrigieron los errores que podían ser subsanados con evidencia suficiente y solo se eliminaron los registros que permanecían sin validez.

El 97,6 % restante de la pérdida, correspondiente a 9.065.436 registros, se explica por la ausencia de coincidencias de identificador. De este grupo, aproximadamente 4,55 millones de registros (49 %) corresponden a censura estructural, debido a que la ventana esperada para presentar Saber Pro se encuentra después de 2024 o aún no se había alcanzado al momento del corte. El 48,5 % restante (4,51 millones) pertenece a cohortes con una ventana de observación completa, por lo que su ausencia de coincidencia probablemente refleja que los estudiantes no presentaron Saber Pro, una situación atribuible a la dinámica del sistema educativo y no a una falla de la base de datos.

6. Reproducibilidad y automatización

El proceso fue desarrollado en RStudio, manteniendo las operaciones de importación, limpieza, homologación y unión dentro del código. Esta estrategia permitió evitar modificaciones manuales sobre los archivos originales y garantizar la trazabilidad de las transformaciones realizadas. En términos generales, el flujo reproducible siguió nueve etapas: archivo original, importación, inspección, limpieza, homologación, validación, consolidación, vinculación y validación final.

Bajo esta estructura, la incorporación de un nuevo periodo puede realizarse siguiendo el mismo procedimiento. Primero, se incorpora el archivo y se revisan su estructura, dimensiones y diccionario de variables. Posteriormente, se identifican las variables equivalentes y se homologan sus nombres, tipos y categorías cuando es necesario. Una vez ejecutados los controles de datos faltantes, el nuevo periodo se integra a la base consolidada y se aplica el criterio temporal correspondiente. Finalmente, se ejecuta nuevamente la vinculación y se validan las dimensiones y los resultados obtenidos.

De esta manera, el proceso no depende de modificaciones manuales específicas para cada periodo, sino de una secuencia estandarizada que facilita su reproducción, actualización y trazabilidad.

7. Limitaciones

Una de las principales limitaciones del proyecto fue la heterogeneidad de las bases a través del tiempo. Los cambios en nombres, tipos, categorías y formas de almacenamiento hacen que la consolidación longitudinal no pueda realizarse simplemente concatenando archivos.

Otra limitación corresponde a la disponibilidad y cobertura temporal de los datos. No todos los estudiantes que aparecen en Saber 11 necesariamente cuentan con un registro posterior en Saber Pro. Por ello, la ausencia de una coincidencia no debe interpretarse automáticamente como un error en el proceso de vinculación.

El criterio de rezago mínimo de dos años también representa una decisión metodológica. Aunque permite controlar la coherencia temporal de las vinculaciones, pueden excluir estudiantes cuyas trayectorias académicas presenten una separación diferente entre ambas pruebas.

Asimismo, el volumen de información generó restricciones de memoria y procesamiento. Esto llevó a utilizar una estrategia progresiva y a limitar las operaciones sobre variables que no fueran necesarias para el objetivo de integración.

Finalmente, los puntajes no deben asumirse automáticamente como perfectamente comparables entre todos los años. Las diferencias en escalas, representaciones y condiciones de aplicación deben revisarse antes de realizar análisis longitudinales. El caso de los puntajes de Saber Pro 2014-2015 demuestra la necesidad de verificar las características específicas de cada periodo.

Por esta razón, cualquier análisis posterior que utilice la base debería considerar especialmente las cohortes con cobertura parcial, las diferencias temporales entre las pruebas y la comparabilidad de los puntajes entre periodos.

8. Uso de inteligencia artificial

La inteligencia artificial fue utilizada como una herramienta de apoyo durante diferentes etapas del proyecto, principalmente para proponer procedimientos en R, explicar mensajes de error, revisar alternativas de limpieza, orientar sobre operaciones de unión y contribuir a estructurar las decisiones metodológicas.

Entre sus principales aportes se encontró la organización del flujo de trabajo, la propuesta de controles de calidad, la interpretación de errores de R, la orientación sobre operaciones Join y la identificación de la necesidad de revisar las variables antes de homologarlas. También fue utilizada como apoyo para estructurar procedimientos de conteo de valores faltantes y documentar las decisiones adoptadas.

Sin embargo, las respuestas generadas por IA no fueron aceptadas de manera automática. Los procedimientos sugeridos fueron contrastados mediante la ejecución real del código en RStudio, la revisión de dimensiones y frecuencias, la inspección de tipos de datos y la consulta de ellos diccionarios correspondientes. Cuando una propuesta generaba errores no coincidía con la estructura real de las bases, el procedimiento era corregido antes de continuar.

En consecuencia, la IA se utilizó como herramienta de asistencia técnica y razonamiento, mientras que la validación final de las decisiones dependió de su comprobación sobre los datos reales y de su coherencia con la documentación oficial.

9. Anexos

9.1. Anexo 1. Bitácora de uso de inteligencia artificial

En este anexo se presenta la bitácora de uso de herramientas de inteligencia artificial durante el desarrollo del proyecto. El documento registra las actividades en las que se empleó esta herramienta, así como su propósito dentro del proceso y el tratamiento dado a los resultados obtenidos.

Enlace:

<https://drive.google.com/file/d/1SqG1k8mdjWdZv-tvtqcx3DmMn59lxWuO/view?usp=sharing>

9.2. Anexo 2. Análisis estadístico de resultados

Además del proceso de construcción, limpieza y vinculación de la base de datos longitudinal de las pruebas Saber 11 y Saber Pro, la información consolidada permitió realizar análisis estadísticos complementarios orientados a explorar patrones, tendencias y relaciones entre algunas de las variables de interés. Estos análisis, aunque no constituían un requisito del proyecto, fueron desarrollados como un valor agregado por iniciativa del equipo, con el propósito de profundizar en los resultados obtenidos y evidenciar el potencial de la base construida para el análisis de las trayectorias académicas de los estudiantes.

Enlace:

https://drive.google.com/file/d/1Y8XV1WRCJR1j0PR0DhLQ2eAEx2_1G7X3/view?usp=drive_link